

Causal 추론이 가능한 골다공증 분류 모델 개발

Development of an osteoporosis classification model capable of causal inference

요 약

본 논문에서는 어깨 x-ray 이미지만으로도 골다공증을 정확하게 진단할 수 있는 모델을 개발하고자 한다. 의료 데이터의 특성상, 골다공증 환자의 어깨 x-ray 데이터의 수가 적기 때문에 다양한 방법으로 Masked autoencoder와 roatation proxy-task self supervised learning을 적용해 적은 데이터로도 높은 성능을 낼 수 있는 모델 학습 방법을 연구한다. Accuracy와 ROC-AUC뿐만 아니라 GradCam방법으로 계산한 모델과 의료 전문가의 판단 근거 유사성을 모델 성능 지표로 사용하여, 더욱 신뢰성 있고 정확한 골다공증 진단 모델과 그 학습 방법을 제안하고자 한다.

1. 서 론

골다공증으로 인한 골절은 환자의 생활 질을 크게 저하시키며, 심각한 경우 사망에 이르게 할 수도 있다. 이에 골다공증을 초기에 정확하게 진단하는 것의 중요성은 커지고 있다. 전통적으로 골다공증의 진단은 골밀도 측정에 의존해왔으나, 해당 방법은 비용과 접근성의 문제가 존재한다.

이러한 신속하고 정확한 골다공증 진단의 필요성을 기반으로 본 논문에서는 어깨 X-ray 이미지를 사용하여 골다공증을 진단할 수 있는 모델을 개발하고자 한다. 또한 질병 진단이라는, 판단의 근거가 합리적이고 정확해야 하는 문제의 특수성을 고려해 판단의 근거가 causal한 모델의 개발을 목표로 한다.

해당 목표에서 어깨 골다공증을 진단하는 모델을 학습시킬 수 있는 데이터의 수가 절대적으로 적은 것이 가장 중요한 문제점이라고 할 수 있다. 이를 위해 Masked Autoencoder, Proxy task self supervised learning을 통해 적은 데이터셋에서도 문제를 정확하게 풀기 위한 모델의 학습 방법에 대해 연구하고자 한다. 이와 더불어, 설명 가능한 AI 기술 중 하나인 GradCAM을 활용하여 모델이 이미지의 어느 부분을 보고 결정을 내렸는지 시각적으로 나타내어, 모델의 판단 근거를 투명하게 제시하고자 한다. 이는 의료 전문가들이 AI의 결정을 더 잘 이해하고 신뢰할 수 있게 함으로써, 진단의 정확성을

높이는 데 기여할 수 있다.

해당 연구를 통해 기존의 골다공증 진단 방법을 효과적으로 보완하여 초기 진단과 치료에 중요한 기여를 할 수 있다. 또한 데이터 효율적인 모델 학습 방법과, 해당 방법들의 정확도와 설명 가능성의 비교를 통해 의료분야를 포함한 다양한 문제에서 활용될 수 있다.

2. 연구 배경 및 관련 연구

MAE(Masked Auto Encoder). 입력 이미지에서 무작위로 패치를 마스킹하고, 인코더가 보이는 패치들만 처리하도록 하며, 디코더는 잠재적인 표현과 마스크 토큰을 통해 원본 이미지를 재구성한다. 높은 비율(예: 75%)의 이미지를 마스킹하는 것이 효과적인 자기지도 학습 과제를 생성하고, 이는 비전 태스크에서의 학습에 도움이 된다. MAE를 통한 사전 학습을 수행하는 과정은 비지도 학습 방식으로 진행되며, 이미지의 일부를 마스킹하고 남은 정보를 기반으로 원본 이미지를 재구성하여 모델이 중요한 특징을 학습하도록 한다. 이러한 설계를 통해 훈련 속도를 3배 이상 향상시키고 정확도를 개선할 수 있으며 큰 모델을 효율적으로 학습시킬 수 있다, 이러한 접근 방식은 이미지 인식에서 높은 용량의 모델이 잘 일반화되는 것을 가능하게 한다.[1]

Rotation Proxy-task. 이미지 회전을 통한 자기 지도 학습 방법으로, 모델이 이미지의 회전된 상태를 예측하도록 함으로써 이미지 특징을 파악하고 이를 분류 작업에 활용할 수 있는 특성을 학습하도록 한다. 이 과정을 통해 모델은 회전에 따른 이미지 변형을 인식하고, 이러한 변형이 골다공증의 진단과 어떠한 연관성을 가지는지 학습할 수 있다. 추가적으로, Rotation Proxy-task를 통해 향상된 특징 추출 능력은 모델이 실제 진단 시 골다공증을 보다 정확히 분류하는 데 기여할 것으로 기대된다.

Causal 추론의 의미와 분석 방법: Grad-CAM(Gradient-weighted Class Activation Mapping)은 목표 개념에 대한 그라디언트를 활용하여 마지막 컨볼루션 레이어로의 그라디언트 흐름을 기반으로 중요 영역을 강조하는 지도를 생성한다. 다양한 CNN 모델에 적용 가능하며 고해상도 시각적 설명과 결합하여, 클래스 구별이 가능한 고해상도 시각화를 생성할 수 있다. 이를 통해 모델이 특정 결정을 내릴 때 중요하다고 판단한 이미지의 특정 영역을 상세하게 보여준다. 최근 causal 추론이 가능한 모델에 대한 관심이 높아지며 다양한 이미지 분류, 시각적 질문 응답(VQA) 모델에 적용하는 연구가 진행되고 있다.

3. 연구 방법

학습 데이터. 골다공증 분류 모델 학습을 위한 어깨 X-ray 이미지는 총 1798장 (골다공증 환자 1020명, 정상 778명)이며, train, validation, test는 0.77, 0.11, 0.12의 비율로 나누었다. 모든 이미지는 posteroanterior (PA) 혹은 anteroposterior (AP) view이며, 평균 0.5256, 표준편차 0.252로 정규화하였다. 사전 학습하는 데에 사용되는 흉부 X-ray 이미지 또한 모두 posteroanterior (PA) 혹은 anteroposterior (AP) view이다. 질병 진단에 필수적인 영역이 사라지지 않도록 0.5~1.0크기로 RandomResizeCrop을 진행하였고, RandomHorizontalFlip을 진행하였다.

진단 모델. 골다공증 진단 모델로서 Densenet121과 ViT-small를 사용하였다. 어깨 X-ray의 데이터 수가 부족한 점을 감안하여 모델의 데이터 효율적인 학습을 위해 MAE 방식을 통해 사전학습된 두 모델[2]을 기본적으로 사용하였으며, 구체적으로는 의료 영상인 어깨 X-ray와 유사하면서 상대적으로 대용량의 데이터가 존재하는 흉부 X-ray에서 사전학습된 모델을 사용하였다. 이를 통해 흉부 X-ray에서 X-ray 이미지의 자체적인 특징을 사전 학습하는 효과를 기대할 수 있다.

사전학습 시나리오. 흉부 X-ray 이미지에서 MAE를 통해 사전 학습된 모델을 기본으로 하여 추가적인 자기 지도학습 방법들을 활용해 더욱 정확하고 효율적인 골다공증 진단 모델 개발한다. 이를 위해 4가지 사전학습 시나리오를 설계하였다.

1. 흉부 X-ray MAE
 2. 흉부 X-ray MAE + 어깨 X-ray MAE(random crop)
 3. 흉부 X-ray MAE + 어깨 X-ray MAE(center crop)
 4. 흉부 X-ray MAE + 어깨 X-ray Rotation Proxy
- 두 단계의 self supervised learning을 통해 더욱 정교한 특징을

학습할 수 있도록 하며, 사전 학습하는 데이터의 종류, 사전 학습에서의 task에 차이를 두어 비교분석한다.

Masked Auto Encoder. encoder로서는 vanilla ViT를 사용하였으며, 계산과 저장공간 효율성을 위해 masking되지 않은 이미지 patch만을 사용하였다. 인접 pixel간의 정보 중복성이 일반 이미지보다 높은 X-ray 이미지의 특성 상, masking 비율은 90%로 설정하였다[3]. 흉부 X-ray를 활용한 선행 연구에서는 이미지의 모든 부분에서 랜덤하게 resizedcrop과 masking을 진행하였다[4]. 하지만 본 연구에서는 이미지의 특정 영역이 골다공증 판단 근거와 매우 높은 연관성을 가지는 특징이 존재한다. 따라서 해당 영역에서 더 많은 resizedcrop과 masking을 진행하고, 랜덤하게 사전학습을 한 경우와 비교 분석하고자 한다.

Data Augmentation. 이미지 데이터 증강을 위해 RandomResizedCrop, ImageRotation을 사용하였다. 그중 rotation proxy task는 어깨 X-ray 이미지에 대해 0도, 90도, 180도, 270도의 네 가지 회전을 적용하고, 모델이 이를 정확히 예측할 수 있도록 학습을 진행하였다.

Fine-Tuning. 자기 지도학습을 통한 사전학습을 거친 후, 골다공증을 진단하는 task에서의 모델 성능을 최적화하기 위해 FineTuning 단계를 진행한다. 이를 통해 최종적으로 모델이 골다공증 환자의 X-ray 이미지에서 질병의 특징을 더 정밀하게 인식하고 정확한 진단을 내릴 수 있도록 한다. RandomAug의 강도를 6, weight decay 0.05, layer-wise learning rate decay 0.55[5]로 설정하였다.

Fine-tuning 과정에서는 사전 학습된 모델의 가중치를 최대한 보존하면서 미세 조정할 수 있도록 6.25e-05의 learning rate를 설정하였다. 이는 기존에 학습된 네트워크 구조와 파라미터에 큰 변화를 주지 않으면서도, 새로운 데이터에 효과적으로 적응할 수 있도록 하기 위함이다.

4. 실험 결과

| Model | Learning Method | ACC | AUC |
|-------------|---|--------------|--------------|
| Densenet121 | 흉부x-ray MAE | 0.727 | 0.819 |
| Densenet121 | 흉부x-ray MAE 어깨x-ray MAE(random crop) | <u>0.768</u> | <u>0.848</u> |
| Densenet121 | 어깨 x-ray rotation proxy | 0.744 | 0.819 |
| ViT-small | 흉부 x-ray MAE | 0.756 | 0.842 |

표1. 사전학습 시나리오와 진단 모델 종류(Densenet121, ViT-small)에 따른 어깨 x-ray 골다공증 진단 모델의 ACC, AUC

실험 결과, 흉부 X-ray 이미지를 활용한 MAE 방법으로 사전 학습을 한 모델의 경우, densenet121보다 ViT-small에서 조금 더 높은 성능을 보였다. 추가적인 사전학습을 진행했을 때, 어깨 x-ray를 사용해 MAE를 진행하고 골다공증을 진단 했을 때의 AUC와 ACC가 어깨 x-ray를 사용해 rotation proxy task

self supervised learning을 진행했을 때보다 유의미하게 높은 결과를 내었다.

5. 결론 및 향후연구

본 논문에서는 흉부 X-ray를 이용한 Masked Autoencoder (MAE)를 통한 사전 훈련과 어깨 X-ray 이미지에 대한 응용은 의료 영상 분석에서 매우 유망한 접근법을 제시한다. 특히 골다공증 진단과 같은 특정 의료 진단에서 더 나은 모델 성능과 일반화 능력을 추구하며 모델간 성능분석과 비교를 통한 유의미한 어깨 골다공증 판별 방법론을 제시하고자 한다. 향후 연구로는 X-ray 뿐 아니라 환자의 임상 데이터를 포함하는 다중 모델 접근 방식을 개발하여 진단 정확성을 추가로 향상시킬 수 있을 것으로 기대한다.

본 연구의 한계점으로는 활용 가능한 데이터셋의 부족으로 인하여 충분한 학습 대상 표본을 확보하지 못한 것이다. 이로 인하여 데이터의 정합성 확보에 일부 어려움이 있었던 점은 향후 보완해야 할 사항으로 보인다.

참 고 문 헌

- [1] Delving_into_Masked_Autoencoders_for_Multi_Label_Thorax_Disease_Classification
- [2] Masked Autoencoders Are Scalable Vision Learners Kaiming He*,† Xinlei Chen* Saining Xie Yanghao Li Piotr Dollar Ross Girshick, 2021
- [3] Delving into Masked Autoencoders for Multi-Label Thorax Disease Classification Junfei Xiao Yutong Bai Alan Yuille Zongwei Zhou*, 2022
- [4] Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization Ramprasaath R. Selvaraju · Michael Cogswell · Abhishek Das · Ramakrishna Vedantam · Devi Parikh · Dhruv Batra